

Evaluasi Deteksi Objek Kecil dan Berkelompok pada YOLO dengan Variasi Resolusi Input pada VisDrone2019-DET

Serly Eldina

26/589324/PPA/07352

Magister Kecerdasan Artifisial

Fakultas Matematika dan Ilmu

Pengetahuan Alam

Universitas Gadjah Mada

Yogyakarta, Indonesia

serlyeldina@mail.ugm.ac.id

<https://colab.research.google.com/drive/1fCSQfmRMYxnjYQqq3WgZMnEeLPy9us#scrollTo=77c5ccf0>

ABSTRAK — YOLO merupakan metode deteksi objek real-time yang memiliki keterbatasan dalam mendeteksi objek berukuran kecil yang muncul secara berkelompok. Penelitian ini menguji apakah keterbatasan tersebut masih terdapat pada model YOLO11n sebagai YOLO modern serta mengevaluasi pengaruh resolusi input terhadap kinerja deteksi. Eksperimen dilakukan menggunakan dataset VisDrone2019-DET yang terdiri atas 6.471 citra pelatihan dan 548 citra validasi dengan 10 kelas objek. YOLO11n di-fine-tuning menggunakan dua resolusi input, yaitu 640×640 sebagai baseline dan 1280×1280 sebagai konfigurasi resolusi tinggi. Kedua konfigurasi dilatih selama 10 epoch menggunakan seed acak dan model pretrained yang sama. Kinerja dievaluasi menggunakan mAP@0.5 dan mAP@0.5:0.95, dengan analisis tambahan berdasarkan ukuran objek small, medium, dan large serta beberapa kasus kegagalan. Hasil menunjukkan bahwa peningkatan resolusi input meningkatkan mAP@0.5 dari 0.2287 menjadi 0.3792 dan mAP@0.5:0.95 dari 0.1279 menjadi 0.2277. Untuk objek kecil, mAP@0.5:0.95 meningkat dari 0.0451 pada 640×640 menjadi 0.1237 pada 1280×1280. Namun, kasus kegagalan dengan tingkat miss tinggi masih ditemukan pada citra yang padat oleh objek kecil. Dengan demikian, resolusi tinggi meningkatkan kinerja deteksi, khususnya pada objek kecil, tetapi tidak sepenuhnya menghilangkan kesulitan dalam mendeteksi objek kecil dan berkelompok. Hasil ini menunjukkan bahwa keterbatasan yang dilaporkan pada penelitian YOLO awal masih dapat diamati pada YOLO11n, meskipun tingkat kesulitannya dapat dikurangi melalui peningkatan resolusi input.

Kata kunci— YOLO11n, VisDrone2019-DET, deteksi objek, objek kecil, citra padat, resolusi input.

I. PENDAHULUAN

Deteksi objek merupakan salah satu tugas penting dalam computer vision yang bertujuan mengidentifikasi objek sekaligus menentukan lokasinya pada citra. Perkembangan deep learning menghasilkan detektor dua tahap dan satu tahap, termasuk Fast R-CNN, Faster R-CNN, dan SSD [1], [2], [3]. You Only Look Once (YOLO) merupakan detektor satu tahap yang memformulasikan deteksi objek sebagai satu permasalahan regresi dan memprediksi bounding box serta probabilitas kelas secara langsung dari keseluruhan citra [4]. Pendekatan terpadu tersebut memungkinkan proses deteksi yang cepat sehingga sesuai untuk aplikasi real-time.

Meskipun efisien, penelitian YOLO asli melaporkan keterbatasan dalam mendeteksi objek kecil yang muncul secara berkelompok. Paper tersebut menjelaskan bahwa keterbatasan spasial pada arsitektur deteksinya membatasi jumlah objek berdekatan yang dapat diprediksi. Jaringan juga menggunakan beberapa tahap downsampling sehingga fitur yang digunakan untuk prediksi bounding box relatif lebih kasar [4]. Kondisi tersebut menyulitkan lokalisasi ketika objek berukuran kecil dan tersebar secara padat.

Keterbatasan tersebut sangat relevan pada citra udara. Citra drone memiliki objek dengan skala, sudut pandang, dan kepadatan yang beragam, sementara banyak objek hanya menempati sebagian kecil area citra. VisDrone-DET2018 dikembangkan sebagai benchmark untuk deteksi objek berbasis drone dan menyediakan kondisi yang menantang dengan variasi skala serta kepadatan objek [5]. Detektor objek modern memiliki perbedaan yang signifikan dibandingkan arsitektur YOLO asli. Representasi fitur multi-skala juga banyak digunakan untuk meningkatkan deteksi pada berbagai ukuran objek, seperti pada Feature Pyramid Networks (FPN) [6]. Penelitian ini kemudian menguji apakah keterbatasan deteksi objek kecil masih terlihat pada model YOLO modern. Eksperimen menggunakan YOLO11n dan peningkatan resolusi input sebagai intervensi. YOLO11n dirilis oleh Ultralytics pada 2024; pengembang menyatakan


bahwa belum terdapat paper penelitian formal yang secara khusus membahas YOLO11 dan merekomendasikan situasi perangkat lunak/dokumentasinya ketika digunakan [7].

Pertanyaan penelitian dalam studi ini adalah: Apakah keterbatasan dalam mendeteksi objek kecil dan berkelompok yang dilaporkan pada model YOLO awal masih terdapat pada YOLO11n, dan apakah peningkatan resolusi input dapat meningkatkan kinerja deteksi? Desain eksperimen mengikuti Opsi C pada tugas, yaitu menguji keterbatasan objek kecil berkelompok menggunakan YOLO modern, menerapkan minimal satu intervensi, serta melaporkan $mAP@0.5$ dan $mAP@0.5:0.95$ berdasarkan ukuran objek.

II. METODE

Metode YOLO memformulasikan deteksi sebagai satu permasalahan regresi, yaitu satu jaringan convolutional memprediksi bounding box dan probabilitas kelas dari keseluruhan citra [4]. Pada pengaturan PASCAL VOC, model asli membagi citra menjadi grid 7×7 , memprediksi dua bounding box pada setiap sel grid, dan menggunakan tensor keluaran berukuran $7 \times 7 \times 30$. Arsitekturnya terdiri atas 24 convolutional layers yang diikuti dua fully connected layers, dengan ukuran input deteksi 448×448 . Keterbatasan yang dilaporkan tersebut menjadi dasar penelitian ini; eksperimen tidak bertujuan mereplikasi implementasi YOLO asli secara identik, tetapi menguji apakah keterbatasan tersebut masih dapat diamati pada model YOLO modern.

Implementasi berbeda dari paper asli dalam empat aspek utama. Pertama, model yang digunakan adalah YOLO11n, bukan arsitektur YOLO asli, dan model diinisialisasi menggunakan model pretrained modern sebelum dilakukan fine-tuning [7]. Kedua, dataset yang digunakan adalah VisDrone2019-DET, bukan PASCAL VOC, karena dataset tersebut sesuai untuk skenario dengan banyak objek kecil dan berkelompok [5]. Ketiga, eksperimen membandingkan input 640×640 dan 1280×1280 , sedangkan sistem asli menggunakan 448×448 ; resolusi yang lebih tinggi digunakan sebagai intervensi untuk menguji apakah tambahan informasi spasial dapat meningkatkan deteksi objek kecil. Keempat, pelatihan dan evaluasi menggunakan implementasi Ultralytics modern, bukan pipeline pelatihan YOLO asli. Perbedaan tersebut disengaja karena penelitian ini menguji klaim dari paper 2016 pada model YOLO modern, bukan melakukan replikasi identik terhadap sistem tahun 2016.



Gambar 1. Alur Penelitian


A. Dataset VisDrone2019-DET

Eksperimen menggunakan VisDrone2019-DET. Data pelatihan dan validasi diunduh secara otomatis, kemudian anotasi dikonversi ke format YOLO. Data validasi digunakan untuk evaluasi model. Prosedur eksperimen menggunakan random seed 42. Pemilihan dataset didukung oleh paper benchmark VisDrone.

Tabel 1. Konfigurasi Dataset

Parameter	Nilai
Dataset	VisDrone2019-DET
Citra pelatihan	6,471
Citra validasi	548
Objek validasi	38,759
Jumlah kelas	10
Pembagian data	Pelatihan / Validasi
Random seed	42

Objek pada data validasi didominasi oleh objek berukuran kecil: sekitar 60,49% small, 33,98% medium, dan 5,53% large. Distribusi tersebut menjadikan VisDrone sesuai untuk menguji keterbatasan deteksi objek kecil.



Gambar 2. Distribusi ukuran objek pada data validasi VisDrone.

B. Model dan Setup Eksperimen

Model yang digunakan adalah YOLO11n pretrained yang di-fine-tuning pada VisDrone2019-DET. Kedua eksperimen menggunakan model pretrained, fraksi dataset, jumlah epoch, dan random seed yang sama. Variabel eksperimen yang dibedakan adalah resolusi input.

Tabel 2. Konfigurasi Eksperimen

Parameter	YOLO11n-640	YOLO11n-1280
Model	YOLO11n	YOLO11n
Resolusi input	640×640	1280×1280
Epoch	10	10
Batch size	16	4
Pretrained	Ya	Ya
Random seed	42	42
Fraksi dataset	1.0	1.0

Eksperimen dilakukan di Google Colab menggunakan GPU NVIDIA Tesla T4. Batch size dikurangi dari 16 menjadi 4 pada resolusi 1280×1280 karena resolusi input yang lebih tinggi membutuhkan memori GPU yang lebih besar. Eksperimen menggunakan Ultralytics 8.4.172 dan model YOLO11n.

C. Metrik Evaluasi

Metrik utama yang digunakan adalah $mAP@0.5$ dan $mAP@0.5:0.95$. Evaluasi tambahan dilakukan berdasarkan ukuran objek small, medium, dan large, serta pemeriksaan kasus kegagalan pada deteksi objek kecil. Evaluasi berdasarkan ukuran, yang menyediakan kerangka evaluasi

standar untuk lokalisasi dan deteksi objek [8]. Eksperimen dibatasi pada 10 epoch dan dua resolusi agar perbandingan tetap terkontrol. Konfigurasi 640×640 digunakan sebagai baseline, sedangkan 1280×1280 digunakan sebagai pembandingan.

III. HASIL


A. Kinerja Deteksi Keseluruhan

Peningkatan resolusi input menghasilkan peningkatan kinerja yang jelas. mAP@0.5 meningkat sebesar 0.1504, dari 0.2287 menjadi 0.3792, sedangkan mAP@0.5:0.95 meningkat sebesar 0.0997, dari 0.1279 menjadi 0.2277. Peningkatan tersebut disertai biaya komputasi yang lebih tinggi: waktu pelatihan meningkat dari 22,49 menjadi 60,64 menit dan waktu validasi dari 0,326 menjadi 0,434 menit.

Tabel 3. Kinerja Deteksi Keseluruhan

Eksperimen	Input	mAP@0.5	mAP@0.5:0.95	Pelatihan (menit)	Validasi (menit)
YOLO11n-640	640×640	0.2287	0.1279	22.4939	0.3258
YOLO11n-1280	1280×1280	0.3792	0.2277	60.6394	0.4340


Untuk visualisasi perbandingan pada Gambar 3 berikut :




Gambar 3. Perbandingan mAP@0.5 dan mAP@0.5:0.95 antara YOLO11n-640 dan YOLO11n-1280.

B. Training Model

Selama pelatihan, kedua konfigurasi menunjukkan peningkatan kinerja dalam sepuluh epoch. Pada konfigurasi 640×640, mAP@0.5 validasi meningkat dari 0,110 pada epoch 1 menjadi sekitar 0,238 pada epoch 10. Pada 1280×1280, nilainya meningkat dari sekitar 0,221 menjadi 0,393. Konfigurasi resolusi tinggi tetap berada di atas baseline selama proses pelatihan. Loss juga mengalami penurunan. Pada 640×640, box loss turun dari 1,997 menjadi 1,594, classification loss dari 2,759 menjadi 1,199, dan DFL loss dari 1,049 menjadi 0,914. Pada 1280×1280, box loss turun dari 1,708 menjadi 1,402, classification loss dari 2,405 menjadi 1,108, dan DFL loss dari 1,155 menjadi 0,990.



Gambar 4. Kurva pelatihan dan validasi YOLO11n-640



Gambar 5. Kurva pelatihan dan validasi YOLO11n-1280.

C. Hasil Berdasarkan Ukuran Objek

Evaluasi berdasarkan ukuran objek dilakukan untuk melihat pengaruh peningkatan resolusi terhadap kemampuan deteksi objek small, medium, dan large. Hasil masing-masing ditunjukkan pada Tabel 4 dan Tabel 5.


Tabel 4. mAP@0.5 Berdasarkan Ukuran Objek

Resolusi	Semua	Small	Medium	Large
640×640	0.2031	0.1082	0.3264	0.4630
1280×1280	0.3552	0.2490	0.5130	0.5710

Tabel 5. mAP@0.5:0.95 Berdasarkan Ukuran Objek

Resolusi	Semua	Small	Medium	Large
640×640	0.1176	0.0451	0.1911	0.3544
1280×1280	0.2155	0.1237	0.3308	0.4519
Peningkatan	+0.0979	+0.0786	+0.1397	+0.0975

Peningkatan resolusi memperbaiki kinerja pada seluruh kategori ukuran objek. Untuk objek kecil, mAP@0.5 meningkat dari 0.1082 menjadi 0.2490, sedangkan mAP@0.5:0.95 meningkat dari 0.0451 menjadi 0.1237. Namun, kinerja objek kecil tetap berada di bawah objek medium dan large pada resolusi 1280×1280. Tabel berdasarkan ukuran objek menggunakan prosedur evaluasi kategori area COCO yang terpisah [8]. Oleh karena itu, nilai agregat “All” tidak boleh dianggap identik dengan nilai validasi Ultralytics utama.



Gambar 6. Kinerja deteksi berdasarkan ukuran objek: mAP@0.5 dan mAP@0.5:0.95

D. Hasil Per Kelas

Pada resolusi 1280×1280, nilai mAP@0.5 validasi tertinggi diperoleh pada kelas car (0.808), bus (0.480), pedestrian (0.479), dan motor (0.463). Nilai terendah diperoleh pada awning-tricycle (0.110) dan bicycle (0.141). Seluruh sepuluh kelas mengalami peningkatan ketika resolusi dinaikkan

E. Kasus Kegagalan

Untuk menganalisis keterbatasan deteksi objek kecil pada kondisi padat, dilakukan pemeriksaan terhadap beberapa citra yang memiliki jumlah objek kecil dalam jumlah tinggi. Tabel 6 menunjukkan tiga kasus kegagalan terpilih yang memiliki 261–280 objek kecil pada ground truth.

Tabel 6. Kasus Kegagalan Objek Kecil Terpilih

Citra	GT Small	Terdeteksi	Terlewat	Tingkat Miss
0000295_02400_d_0000033.jpg	280	55	225	0.804
0000295_01800_d_0000030.jpg	269	49	220	0.818
0000295_02000_d_0000031.jpg	261	53	208	0.797

Kasus terpilih berisi ratusan objek ground truth berukuran kecil dan menunjukkan tingkat miss yang tinggi. Tingkat miss tertinggi adalah 0,818, dengan 49 dari 269 objek ground truth kecil berhasil dicocokkan berdasarkan kriteria pencocokan yang digunakan dalam eksperimen.

Figure case: 0000295_02400_d_0000033.jpg (missed by baseline = 225/280)



Gambar 7. Visualisasi hasil ground truth, YOLO11n-640, dan YOLO11n-1280 untuk 0000295_02400_d_0000033.jpg.

Figure case: 0000295_01800_d_0000030.jpg (missed by baseline = 220/269)



Gambar 8. Visualisasi hasil ground truth, YOLO11n-640, dan YOLO11n-1280 untuk 0000295_01800_d_0000030.jpg.

Figure case: 0000295_02000_d_0000031.jpg (missed by baseline = 208/261)



Gambar 9. Gambar 8. Visualisasi hasil ground truth, YOLO11n-640, dan YOLO11n-1280 untuk 0000295_01800_d_0000031.jpg.

IV. ANALISIS

A. Apakah Keterbatasan Objek Kecil Masih Ada?

Hasil menunjukkan bahwa keterbatasan tersebut masih terlihat pada YOLO11n. Objek kecil secara konsisten memperoleh kinerja lebih rendah dibandingkan objek medium dan large. Pada 1280×1280, mAP@0.5:0.95 objek kecil sebesar 0.1237, dibandingkan 0.3308 untuk objek

medium dan 0.4519 untuk objek large. Kasus kegagalan juga menunjukkan tingkat miss sebesar 0.797–0.818 pada citra yang sangat padat.

Hasil tersebut konsisten dengan paper YOLO asli yang secara eksplisit mengidentifikasi kesulitan pada objek kecil yang muncul secara berkelompok [4]. Namun, penelitian ini tidak menyatakan bahwa YOLO11n mereplikasi kinerja kuantitatif model asli. Arsitektur, dataset, prosedur pelatihan, dan pengaturan evaluasi berbeda. Kesimpulan yang tepat adalah bahwa jenis kesulitan yang sama masih dapat diamati pada model YOLO modern.

B. Pengaruh Resolusi Input yang Lebih Tinggi

Intervensi resolusi tinggi secara jelas meningkatkan kinerja deteksi. mAP@0.5:0.95 keseluruhan meningkat dari 0.1279 menjadi 0.2277, sedangkan mAP@0.5:0.95 objek kecil meningkat dari 0.0451 menjadi 0.1237. Penjelasan yang didukung oleh rancangan eksperimen adalah bahwa resolusi input yang lebih tinggi mempertahankan lebih banyak informasi spasial pada objek kecil. Hasil menunjukkan bahwa intervensi mengurangi, tetapi tidak menghilangkan, keterbatasan tersebut.

C. Citra Padat dan Kasus Kegagalan

Kasus kegagalan terpilih mengandung 261–280 objek ground truth kecil dengan tingkat miss mendekati 0,80. Kasus tersebut memberikan bukti langsung bahwa citra dengan kepadatan objek tinggi masih sulit dideteksi. Paper YOLO asli mengaitkan kesulitan objek berkelompok, antara lain, dengan keterbatasan spasial pada prediksi bounding box [4]. YOLO11n modern mengurangi kesulitan tersebut melalui perbaikan arsitektur, tetapi kasus kegagalan menunjukkan bahwa lokalisasi objek kecil pada citra padat tetap menantang.

D. Perbandingan dengan Paper Asli

Paper YOLO melaporkan 57,9% mAP pada VOC 2012 test set [4]. Nilai tersebut tidak dapat dibandingkan secara langsung dengan mAP@0.5 sebesar 0.2287 dan 0.3792 pada penelitian ini karena dataset, jumlah kelas, versi model, prosedur pelatihan, dan pengaturan evaluasi berbeda. Perbandingan yang relevan untuk tugas ini bersifat kualitatif: paper asli mengidentifikasi objek kecil berkelompok sebagai kelemahan, sedangkan eksperimen ini menunjukkan bahwa objek kecil berkelompok tetap sulit dideteksi oleh YOLO11n pada VisDrone.

Tabel 7. Perbandingan Kualitatif Dengan Yolo sebelumnya

Aspek	YOLO [4]	Penelitian Ini
Model	YOLO	YOLO11n
Dataset	PASCAL VOC	VisDrone2019-DET
Input	448×448 pada sistem asli	640×640 / 1280×1280
Fokus	Deteksi objek umum	Objek kecil dan padat pada citra udara
Temuan	Objek kecil berkelompok sulit dideteksi	Kesulitan masih ada, berkurang pada 1280×1280

E. Komputasi

Konfigurasi 1280×1280 membutuhkan komputasi yang jauh lebih besar. Waktu pelatihan meningkat dari 22,49 menjadi 60,64 menit, atau sekitar 2,7 kali lebih lama. Waktu validasi meningkat dari 0,326 menjadi 0,434 menit, sedangkan waktu prediksi meningkat dari sekitar 0,21 menjadi 0,27 menit. Oleh karena itu, resolusi tinggi bermanfaat ketika akurasi objek kecil diprioritaskan, tetapi menghasilkan biaya komputasi yang tinggi.

F. Keterbatasan Evaluasi

Validasi menunjukkan bahwa beberapa citra validasi memiliki hingga 317 objek. Oleh karena itu, konfigurasi validasi menggunakan max_det=317, bukan nilai default 300. Hal ini penting pada citra padat karena batas deteksi yang terlalu rendah dapat membatasi recall. Kondisi tersebut diperlakukan sebagai keterbatasan eksperimen, bukan sebagai bukti bahwa eksperimen tidak valid. Evaluasi berdasarkan ukuran objek menggunakan prosedur kategori area COCO yang terpisah dari validasi utama Ultralytics. Kedua keluaran tersebut karena itu dilaporkan secara terpisah. Selain itu, hanya dua resolusi input dan sepuluh epoch yang dievaluasi sehingga penelitian ini belum dapat menentukan resolusi atau durasi pelatihan yang optimal

V. KESIMPULAN DAN SARAN

Penelitian ini menguji apakah keterbatasan deteksi objek kecil yang dilaporkan pada paper YOLO asli masih terdapat pada YOLO11n dan apakah peningkatan resolusi input dapat meningkatkan deteksi pada VisDrone2019-DET. Hasil menjawab kedua bagian pertanyaan penelitian. Pertama, keterbatasan tersebut masih terlihat: objek kecil memperoleh kinerja lebih rendah dibandingkan objek medium dan large, serta kasus kegagalan pada citra padat menunjukkan tingkat miss mendekati 0,80. Kedua, peningkatan resolusi dari 640×640 menjadi 1280×1280 secara substansial meningkatkan kinerja deteksi. mAP@0.5 keseluruhan meningkat dari 0.2287 menjadi 0.3792, sedangkan mAP@0.5:0.95 meningkat dari 0.1279 menjadi 0.2277. mAP@0.5:0.95 objek kecil meningkat dari 0.0451 menjadi 0.1237. Dengan demikian, intervensi resolusi tinggi mengurangi tingkat keterbatasan, tetapi tidak menghilangkannya secara keseluruhan.

Keterbatasan utama penelitian adalah penggunaan hanya dua resolusi, jadwal pelatihan sepuluh epoch, penggunaan dataset yang berbeda dari studi YOLO asli, serta batas jumlah

deteksi pada citra padat yang didokumentasikan dalam eksperimen. Penelitian selanjutnya dapat mengevaluasi tiling, pelatihan yang lebih lama, model YOLO yang lebih besar, dan metode yang secara khusus dirancang untuk citra udara dengan kepadatan objek tinggi.

LAMPIRAN

- LINK GOOGLE COLAB:
<https://colab.research.google.com/drive/1fCSQfm-RMYxnjYQqqq3WgZMnEeLPy9us#scrollTo=77c5ccf0>
- LINK GITHUB:
https://github.com/serlyeldina-2/CVL_Assignment02

DAFTAR PUSTAKA

- [1] R. Girshick, "Fast R-CNN," in *Proc. IEEE Int. Conf. Computer Vision (ICCV)*, 2015, pp. 1440–1448.
- [2] S. Ren, K. He, R. Girshick, and J. Sun, "Faster R-CNN: Towards real-time object detection with region proposal networks," in *Advances in Neural Information Processing Systems (NeurIPS)*, vol. 28, 2015, pp. 91–99.
- [3] W. Liu, D. Anguelov, D. Erhan, C. Szegedy, S. Reed, C.-Y. Fu, and A. C. Berg, "SSD: Single shot MultiBox detector," in *Computer Vision – ECCV 2016*, 2016, pp. 21–37.
- [4] J. Redmon, S. Divvala, R. Girshick, and A. Farhadi, "You only look once: Unified, real-time object detection," in *Proc. IEEE Conf. Computer Vision and Pattern Recognition (CVPR)*, 2016, pp. 779–788.
- [5] P. Zhu, L. Wen, D. Du, X. Bian, H. Ling, Q. Hu, Q. Nie, H. Cheng, C. Liu, X. Liu, W. Ma, H. Wu, L. Wang, A. Schumann, et al., "VisDrone-DET2018: The vision meets drone object detection in image challenge results," in *Proc. European Conf. Computer Vision (ECCV) Workshops*, 2018, pp. 437–468.
- [6] T.-Y. Lin, P. Dollár, R. Girshick, K. He, B. Hariharan, and S. Belongie, "Feature pyramid networks for object detection," in *Proc. IEEE Conf. Computer Vision and Pattern Recognition (CVPR)*, 2017, pp. 2117–2125.
- [7] G. Jocher and J. Qiu, "Ultralytics YOLO11," Ultralytics, version 11.0.0, 2024. [Online]. Available: <https://github.com/ultralytics/ultralytics>.
- [8] T.-Y. Lin, M. Maire, S. Belongie, J. Hays, P. Perona, D. Ramanan, P. Dollár, and C. L. Zitnick, "Microsoft COCO: Common objects in context," in *Computer Vision – ECCV 2014*, 2014, pp. 740–755.